

Data Warehouse

I chapitre 1: Intro

I.1 les systemes d'informations classics

- **ont des donnes:**
 - distribuees et heterogenes.
 - detaillees donc sont peu adaptees a l'analyse.
 - volatile donc mal/non historisees.

I.2 systeme d'information decisionnel

I.2.a definition

- **une collection de donnees:**
 - orientees sujet
 - Intergrees
 - Non volatile
 - Historisees
- **mieux organisees pour le/la:**
 - prise de decision
 - collecte
 - stockage
 - analyse
 - presentation
 - transformation de la donnees en information utile

I.3 architecture d'un entrepot de donnees

I.3.a zone de preparation

stockage temporaire

- processus ETL (Extraction, Transformation, Chargement)

I.3.b zone de stockage

stockage permanent

- data mart
- metadonnees

I.3.c zone de presentation

Outils d'analyse programmés

II chapitre 2: Modelisation Multidimensionnelle

Le modèle entité/association (MCD) est trop complet et inadapté à l'analyse décisionnelle.

II.1 principes de modelisation dimensionnelle

deux types de tables:

- tables de faits (ce qu'on mesure)
- tables de dimensions (axes d'analyse)

II.2 Tables de Faits

table principale du modele

- un fait = un sujet d'analyse
- contient:
 - des mesures
 - des clefs etrangeres vers les tables de dimensions

II.3 Aditives des mesures

- Mesures additives
- Mesures semi additives
- Mesures non additives

II.4 Tables de Dimensions

- dimension = axe d'analyse
- peut contenir des hierarchies

II.5 Granularite

niveau de detail de la dimension, granularite

fine = grand niveau de detail

II.6 Evolution des dimesions

II.6.a Dimensions à évolution lente

solutions:


- Écrasement de l'ancienne valeur
- Versionnement
- Valeur d'origine / valeur courante

II.6.b Dimensions à évolution rapide

Solution: isoler les attributs qui changent rapidement


II.7 modeles conceptuels

II.7.a En étoile




- **Avantages:** simple, rapide et peu de jointures
- **Inconvénients:** redondance dans les dimensions

II.7.b En flocon de neige




- **Avantages:** économie d'espace, suppression des redondances.
- **Inconvénients:** plus complexe, plus de jointures, performances moindres.

II.7.c En constellation



plusieurs tables de faits partages des tables de dimensions

II.8 Golfarelli



III Chapitre 3: Méthode de Conception des entrepôts de données

III.1 Etapes de modelisation

1. Choisir le processus métier à modéliser
2. Définir la granularité de chaque processus
3. choisir les dimensions
3. Identifier les faits numériques

III.2 Approche de réalisation

III.2.a Approche Descendante (top-down / inmon)

Concevoir tous les faits et toutes les dimensions avant implémentation.

• Etapes:

1. Collecte des données
 - requêtes types:
 - Analyser ...
 - En fonction ...
 - Pour ...
 - questionnaires
 - règle de gestion
2. Spécification des besoins
 - Construire la matrice des besoins

	Mt locations	Ville	Région	Etat	Année	Mois	Nb jours	CA	Id_Emp	Id_Client	Immat	Type	Marque
Mt locations		✓	✓	✓	✓	✓				✓	✓	✓	✓
Ville													
Région													
Etat													
Année													
Mois													
Nb jours		✓	✓	✓	✓	✓				✓	✓	✓	✓
CA					✓	✓			✓				
Id_Emp													
Id_Client													
Immat													
Type													
Marque													

- Simplifier la matrice

Matrice des besoins										
Paramètres / Indicateur	Ville	Région	Etat	Année	Mois	Id_Emp	Id_Client	Immat	Type	Marque
Mt locations	✓	✓	✓	✓	✓		✓	✓	✓	✓
Nb jours	✓	✓	✓	✓	✓		✓	✓	✓	✓
CA				✓	✓	✓				

3. Formalisation des besoins

- Définition des faits
- Définition des dimensions
- Définition des hiérarchies

• **Avantages:**

- Architecture intégrée, vision claire.
- utilisation des données, pas de redondance.

• **Inconvénients:**

- Méthode lourde et rigide.
- Longue et coûteuse.

III.2.b Approche Ascendante (bottom-up / kimball)

Créer des datamarts indépendants, puis les intégrer progressivement en un entrepôt.

• **Sources possibles:**

- Diagramme E/R, base de données objet.
- Diagramme UML, documents XML.

• **Etapes (à partir d'un diagramme E/R):**

1. Définition des faits

- Analyse du schéma de la source globale
- Détection des classes représentatives de l'analyse
- Choix des mesures d'activités à analyser

2. Définition des dimensions

3. Définition de la granularité

4. Hiérarchisation des dimensions

- **Avantages:** Simple, résultats rapides, efficace à court terme.

• **Inconvénients:**

- Risque de redondances.
- Intégration difficile à long terme.

III.2.c Approche Hybride (Middle-out)

Combiner les deux approches – conception intégrale suivie d'un affinage par les besoins utilisateurs.