

Data Warehouse

I chapitre 1: Intro

I.1 les systemes d'informations classiques

- **ont des données:**
 - distribuées et hétérogènes.
 - détaillées donc sont peu adaptées à l'analyse.
 - volatile donc mal/non historisées.

I.2 système d'information décisionnel

I.2.a définition

- **une collection de données:**
 - orientées sujet
 - Intégrées
 - Non volatile
 - Historisées
- organisées pour le support d'un processus d'aide à la décision.

I.3 architecture d'un entrepôt de données

I.3.a zone de préparation

stockage temporaire

- processus ETL (Extraction, Transformation, Chargement)

I.3.b zone de stockage

stockage permanent

- data mart
- métadonnées

I.3.c zone de présentation

Outils d'analyse programmés

II chapitre 2: Modelisation

Multidimensionnelle

Le modèle entité/association (MCD) est trop complet et inadapté à l'analyse décisionnelle.

II.1 principes de modelisation dimensionnelle

deux types de tables:

- tables de faits (ce qu'on mesure)
- tables de dimensions (axes d'analyse)

II.2 Tables de Faits

table principale du modèle

- **fait** = sujet d'analyse
- **contient:**
 - des mesures
 - des clés étrangères vers les tables de dimensions

II.3 Aditives des mesures

- Mesures additives
- Mesures semi additives
- Mesures non additives

II.4 Tables de Dimensions

- dimension = axe d'analyse
- peut contenir des hiérarchies

II.5 Granularité

niveau de détail de la dimension, granularité fine = grand niveau de détail

II.6 Evolution des dimensions

II.6.a Dimensions à évolution lente

solutions:


- Écrasement de l'ancienne valeur
- Versionnement
- Valeur d'origine / valeur courante

II.6.b Dimensions à évolution rapide

Solution: isoler les attributs qui changent rapidement


II.7 modèles conceptuels

II.7.a En étoile




- **Avantages:** simple, rapide et peu de jointures
- **Inconvénients:** redondance dans les dimensions

II.7.b En flocon de neige




- **Avantages:** économie d'espace, suppression des redondances.
- **Inconvénients:** plus complexe, plus de jointures, performances moindres.

II.7.c En constellation



plusieurs tables de faits partages des tables de dimensions

II.8 Golfarelli



III Chapitre 3: Méthode de Conception des entrepôts de données

III.1 Etapes de modelisation

1. Choisir le processus métier à modéliser
2. Définir la granularité de chaque processus
3. choisir les dimensions
4. Identifier les faits numériques

III.2 Approche de réalisation

III.2.a Approche Descendante (top-down / inmon)

Concevoir tous les faits et toutes les dimensions avant implémentation.

• Etapes:

1. Collecte des données
 - requêtes types:
 - Analyser ...
 - En fonction ...
 - Pour ...
 - questionnaires
 - règle de gestion

2. Spécification des besoins

- Construire la matrice des besoins

	Mt locations	Ville	Région	Etat	Année	Mois	Nb jours	CA	Id_Emp	Id_Client	Immat	Type	Marque
Mt locations		✓	✓	✓	✓	✓				✓	✓	✓	✓
Ville													
Région													
Etat													
Année													
Mois													
Nb jours		✓	✓	✓	✓	✓				✓	✓	✓	✓
CA						✓			✓				
Id_Emp													
Id_Client													
Immat													
Type													
Marque													

- Simplifier la matrice

	Matrice des besoins									
Paramètres / Indicateur	Ville	Région	Etat	Année	Mois	Id_Emp	Id_Client	Immat	Type	Marque
Mt locations	✓	✓	✓	✓	✓		✓	✓	✓	✓
Nb jours	✓	✓	✓	✓	✓		✓	✓	✓	✓
CA				✓	✓	✓				

1. Formalisation des besoins

- Définition des faits
- Définition des dimensions
- Définition des hiérarchies

• Avantages:

- Architecture intégrée, vision claire.
- utilisation des données, pas de redondance.

• Inconvénients:

- Méthode lourde et rigide.
- Longue et coûteuse.

III.2.b Approche Ascendante (bottom-up / kimball)

Créer des datamarts indépendants, puis les intégrer progressivement en un entrepôt.

• Sources possibles:

- Diagramme E/R, base de données objet.
- Diagramme UML, documents XML.

• Etapes (à partir d'un diagramme E/R):

1. Définition des faits

- Analyse du schéma de la source globale.
- Détection des classes représentatives. -

Une classe représentative décrit un événement qui se produit à un instant donné, et contient les mesures d'analyse

- Choix des mesures d'activités à analyser

2. Définition des dimensions

- Détection des classes déterminantes des classes représentatives

Une classe Ci est déterminante d'une classe CR si :
> CR est relié à Ci par un lien de dépendance fonctionnelle directement ou indirectement.

> Cela signifie que Ci fournit un contexte ou une perspective pour analyser CR.

- **Choix des paramètres d'analyse**
 - Les attributs des classes déterminantes qui seront utilisés comme dimensions
- **Définition de la dimension temporelle**

3. Définition de la granularité

4. Hiérarchisation des dimensions

- **Avantages:** Simple, résultats rapides, efficace à court terme.
- **Inconvénients:**
 - Risque de redondances.
 - Intégration difficile à long terme.

III.2.c Approche Hybride (Middle-out)

Combiner les deux approches – conception intégrale suivie d'un affinage par les besoins utilisateurs.

- **Etapes:**

1. Obtenir un ensemble de modèles multidimensionnels à partir d'un diagramme de classes UML
 1. Identification des faits

Une classe H est classée comme une classe de fait si :
> Elle a au moins un attribut numérique non clé
> Elle est liée à au moins à une classe E1 avec une cardinalité (un à plusieurs)

- Effectuer des interviews avec un nombre d'utilisateurs pour établir une liste de processus
2. Définition des dimensions et des hiérarchies

Un processus contient un ensemble des besoins (exigences) des utilisateurs

- Analyser les processus pour choisir et affiner les modèles multidimensionnels en flocon établit.

Évaluer le modèle multidimensionnel obtenu avec les exigences des utilisateurs.

2. Affiner le modèle multidimensionnel par les besoins des utilisateurs

- **Avantages:**
 - Prendre le meilleur des 2 approches
 - Développement d'un modèle de données d'entreprise de manière itérative
 - Développement d'une infrastructure lourde qu'en cas de nécessité
- **Inconvénients:**

- Implique, parfois, des compromis de découpage (dupliquer des dimensions identiques pour des besoins pratiques).